

SISTEMA DE RELATÓRIOS CANNOLI

ENTREGA 1 – PREPARAÇÃO, TRATAMENTO E ANÁLISE DE DADOS

1. Objetivo

O presente projeto tem como objetivo processar a base de dados da foodtech Cannoli para geração de indicadores estratégicos de CRM e vendas, possibilitando análise descritiva, monitoramento de KPIs e segmentação de clientes.

Nesta primeira etapa (Entrega 1), o foco técnico está em:

- Limpeza e padronização dos dados
- Análise exploratória e descritiva
- Geração de métricas iniciais de comportamento e vendas
- Preparação da base para construção de dashboards escaláveis

2. Entendimento do negócio

O projeto visa transformar dados transacionais brutos em informações estratégicas por meio da construção de um dashboard analítico.

O modelo de negócio da foodtech Cannoli é baseado em vendas digitais e no relacionamento com clientes via CRM, no qual campanhas de marketing e o comportamento de compra impactam diretamente a receita e a retenção.

O principal objetivo é assegurar a utilização de dados válidos, consistentes e confiáveis, viabilizando análises precisas sobre o comportamento dos clientes, o desempenho de vendas e a efetividade das campanhas de marketing, com foco no suporte à tomada de decisão estratégica.

Nesta etapa, o foco está na estabilização do pipeline de dados, assegurando a qualidade e a integridade das informações.

3. Identificação das fontes de dados

Foram utilizados sete conjuntos de dados no formato CSV, representando diferentes dimensões do negócio:

- Clientes (CUSTOMER)
- Pedidos (STOREORDER)
- Campanhas (CAMPAIGN)
- Conversões (CAMPAIGNxORDER)
- Lojas (STORE)
- Modelos de comunicação (TEMPLATE)
- Endereços (CUSTOMERADDRESS)

Essas bases permitem uma análise integrada de CRM, vendas e marketing.

- **Tabela: Clientes (CUSTOMER.CSV)**

Nome Original	Nome Ajustado (PT)	Formato/Unidade	Observações
id	ID_Cliente	UUID / Texto	Chave primária. Identificador único do consumidor.
name	Nome_Cliente	Texto	Nome ou identificador. Apresenta variações de maiúsculas.
gender	Genero	Categórico (M/F/N)	Alto índice de valores nulos. "N" indica não informado.
dateofbirth	Data_Nascimento	Data (AAAA-MM-DD)	Usada para segmentação e cálculo de idade.
status	Status_Cadastro	Inteiro (0/1)	Indica se a conta está ativa no CRM.
isenriched	Flag_Enriquecido	Booleano (T/F)	Indica se houve higienização por fontes externas.
enrichedat	Data_Enriquecimento	Timestamp (ISO)	Data da última validação de dados externos.
enrichedby	Fonte_Dados	Texto	Empresa/Sistema que validou o dado (Ex: Cannoli Food).
createdat	Data_Adesao	Timestamp (ISO)	Data de entrada do cliente no ecossistema.
updatedat	Data_Atualizacao	Timestamp (ISO)	Timestamp da última modificação no cadastro.
updatedby	Atualizado_Por	Texto	Usuário ou API que realizou a última alteração.
birthmonth	Mes_Aniversario	Inteiro (1-12)	Campo derivado para campanhas sazonais.
birthday	Dia_Aniversario	Inteiro (1-31)	Campo derivado para ações de CRM.

- **Tabela: Pedidos de Loja (STOREORDER.csv)**

Nome Original	Nome Ajustado (PT)	Formato/Unidade	Observações
id	ID_Pedido	UUID / Texto	Chave primária da transação de venda.
storeid	ID_Loja	UUID / Texto	Chave estrangeira para a tabela de Lojas.
customerid	ID_Cliente	UUID / Texto	Chave estrangeira para a tabela de Clientes.
scheduledat	Data_Agendamento	Timestamp (ISO)	Data/hora prevista para a entrega ou retirada.

totalamount	Valor_Total	Decimal / BRL	Valor líquido final pago (Ticket Médio).
subtotalamount	Subtotal	Decimal / BRL	Valor dos produtos antes de taxas/descontos.
discountamount	Valor_Desconto	Decimal / BRL	Total de abatimentos aplicados no pedido.
taxamount	Valor_Taxas	Decimal / BRL	Custos de frete ou taxas de serviço.
saleschannel	Canal_Venda	Categórico	Origem: IFOOD, SITE, CARDAPIOWEB, etc.
status	Status_Pedido	Inteiro (Código)	Etapa logística (Ex: 16 = Concluído).
ordertype	Modalidade	Categórico	DELIVERY (Entrega) ou INDOOR (Consumo Local).
createdat	Data_Pedido	Timestamp (ISO)	Momento exato em que o pedido foi registrado.
createdby	Agente_Origem	Texto	Sistema que gerou o pedido (Ex: Cannoli API).

- **Tabela: Campanhas (CAMPAIGN.CSV)**

Nome Original	Nome Ajustado (PT)	Formato/Unidade	Observações
segmentid	ID_Segmento	UUID / Texto	Identificador do público-alvo segmentado.
templateid	ID_Modelo	UUID / Texto	Chave para o layout da mensagem (TEMPLATE).
storeid	ID_Loja	UUID / Texto	Loja que disparou a campanha.
name	Nome_Campanha	Texto	Nome descritivo da ação de marketing.
description	Descricao	Texto	Objetivo detalhado da campanha.
type	Tipo_Canal	Inteiro (Código)	Meio de comunicação (Push, SMS, E-mail).
statusend	Status_Final	Inteiro (Código)	Resultado da execução (Sucesso, Falha).
createdat	Data_Criacao	Timestamp (ISO)	Data em que a campanha foi configurada.
customerid	ID_Cliente	UUID / Texto	Cliente alvo do disparo.
sendat	Data_Envio	Timestamp (ISO)	Data/hora do disparo efetivo da mensagem.

- **Tabela: Conversão (CAMPAIGNxORDER.CSV)**

Nome Original	Nome Ajustado (PT)	Formato/Unidade	Observações
campaignid	ID_Campanha	UUID / Texto	Chave estrangeira para Campanhas.
message_id	ID_Mensagem	UUID / Texto	Identificador único do disparo realizado.
sent_at	Data_Disparo	Timestamp (ISO)	Momento do envio da mensagem.
status	Status_Entrega	Inteiro (Código)	Indica se a mensagem foi entregue/lida.
order_at	Data_Conversao	Timestamp (ISO)	Data da compra realizada após a campanha.
order_id	ID_Pedido	UUID / Texto	Pedido resultante da ação de marketing.
totalamount	Receita_Atribuida	Decimal / BRL	Valor da venda convertida pela ação.

- **Tabela: Lojas (STORE.csv)**

Nome Original	Nome Ajustado (PT)	Formato/Unidade	Observações
id	ID_Loja	UUID / Texto	Chave primária da unidade de negócio.
name	Nome_Loja	Texto	Nome fantasia da unidade física.
neighborhood	Bairro	Texto	Localização para análise de cluster regional.
city	Cidade	Texto	Município de operação.
state	UF	Texto (Sigla)	Unidade Federativa.
zipcode	CEP	Texto (8 dígitos)	Código Postal da loja.
status	Status_Loja	Inteiro (0/1)	Indica se a unidade está ativa.
createdat	Data_Abertura	Timestamp (ISO)	Data de início de operações no sistema.

- **Tabela: Modelos (TEMPLATE.csv)**

Nome Original	Nome Ajustado (PT)	Formato/Unidade	Observações
id	ID_Modelo	UUID / Texto	Chave primária do template de mensagem.

name	Nome_Modelo	Texto	Título do template (Ex: Ticket Baixo).
description	Descricao_Modelo	Texto	Gatilho da mensagem (Ex: estimular 2ª compra).
createdat	Data_Criacao	Timestamp (ISO)	Data de criação do modelo.
createdby	Autor	Texto	Usuário responsável pela criação.

• **Tabela: Endereços (CUSTOMERADDRESS.CSV)**

Nome Original	Nome Ajustado (PT)	Formato/Unidade	Observações
customerid	ID_Cliente	UUID / Texto	Chave estrangeira (Join com CUSTOMER).
neighborhood	Bairro_Entrega	Texto	Região de destino do pedido.
city	Cidade_Entrega	Texto	Município do cliente.
state	UF_Entrega	Texto (Sigla)	Estado do cliente.
zipcode	CEP_Entrega	Texto (8 dígitos)	Código Postal para cálculo de frete/logística.

4. Saídas (Outputs)

Métrica / Indicador	Tipo	Descrição / Regra
Total de Clientes	integer	Contagem distinta de clientes únicos
Total de Pedidos	integer	Contagem de pedidos válidos
Clientes Novos	integer	Pedidos do primeiro cliente nos últimos 30 dias
Clientes Frequentes	integer	Clientes com >1 pedido nos últimos 30 dias
Clientes Ativos	integer	Clientes com pelo menos 1 pedido nos últimos 30 dias
Clientes em Alerta	integer	Sem pedidos entre 30-60 dias
Clientes em Atenção	integer	Sem pedidos entre 60-90 dias
Clientes Sumidos	integer	Sem pedidos há mais de 90 dias
Clientes Recuperados	integer	Pedidos após >30 dias de inatividade
Clientes em Fidelização	integer	>=3 compras nos últimos 90 dias
Ticket Médio Geral	float	Média de valor_total dos pedidos válidos
Segmentação por Ticket	integer	Baixo (<50), Médio (50-100), Alto (>100)
Evolução Mensal	tabela	Pedidos e receita por mês, com crescimento %
Vendas por Período do Dia	tabela	Distribuição por Madrugada / Manhã / Tarde / Noite

5. Análise exploratória dos Dados

- Identificação de concentração de pedidos por faixa de valor
- Análise de dispersão (outliers)
- Distribuição de pedidos por canal de venda
- Avaliação de sazonalidade por dia da semana

6. Coleta e Entendimento dos Dados

Os dados foram extraídos do sistema operacional da Cannoli, totalizando mais de 111.000 registros de vendas.

Principais variáveis analisadas:

- Identificação do cliente (customerid)
- Valor do pedido (totalamount)
- Status do pedido
- Datas de criação e agendamento

Durante a análise inicial, foram identificados:

- Valores nulos
- Inconsistências de formato
- Necessidade de padronização de tipos de dados

7. Limpeza e Padronização dos Dados

Foram aplicadas técnicas de limpeza de dados com o objetivo de garantir a qualidade e confiabilidade dos dados:

- Filtragem de pedidos válidos (status: 1, 15, 16, 33, 34, 35, 37, 38)
- Remoção de registros duplicados
- Tratamento de valores nulos
- Padronização de campos categóricos
- Conversão de datas para formato datetime
- Ajuste de fuso horário (UTC-3 – Brasília)

8. Derivação e Transformação de dados

Foram criadas variáveis derivadas para enriquecer a análise:

- Período do dia (Madrugada, Manhã, Tarde, Noite)
- Dia da semana
- Dias desde a última compra (recência)
- Segmentação de clientes por comportamento
- Classificação de ticket médio (Baixo, Médio, Alto)

Essas variáveis permitem análises mais profundas e orientadas à tomada de decisão.

9. Integração dos Dados

Os datasets foram integrados por meio de chaves comuns, como:

- ID do Cliente
- ID do Pedido
- ID da Loja

Essa integração possibilita uma visão unificada do cliente, relacionando comportamento de compra, campanhas e desempenho de vendas.

10. Validação e Integridade dos Dados

Foram realizadas validações para assegurar a consistência:

- Conversão correta de datas e fusos
- Conferência de cálculos de ticket médio
- Verificação de consistência entre indicadores
- Validação de consistência dos totais (ex: soma das categorias de ticket e contagem de clientes por segmento)
- Verificação de ausência de duplicidades após tratamento
- Validação da consistência dos dados após transformação

11. Formatação dos Indicadores (Dashboard)

Os indicadores foram estruturados em dashboard analítico, contemplando métricas de clientes, vendas e comportamento.

12. Dicionário de Variáveis e Metadados

Variável	Tipo Técnico	Descrição	Regra de Limpeza / Transformação
id	Integer	Identificador único do pedido	Chave primária para contagem
customerid	String	Identificador do cliente	Agrupamento CRM
totalamount	Float	Valor total do pedido (R\$)	Cálculo de Ticket Médio
status	Integer	Código de estado do pedido	Mantidos IDs válidos
scheduledat	Datetime	Data de agendamento	Convertido para GMT-3
createdat	Datetime	Data de criação do registro	Fallback quando scheduledat nulo

Variáveis Derivadas:

Variável Derivada	Lógica de Cálculo	Objetivo do Indicador
dia_semana	dt.day_name()	Padrões de consumo semanal
periodo_dia	Faixa horária	Madrugada/Manhã/Tarde/Noite
dias_parado	Data_Ref - Max(Data)	Recência / Churn
faixa_ticket	If/Else	Classificação de Ticket

13. Ajustes Realizados nos Arquivos

Todos os **7 arquivos** foram ajustados para garantir consistência e tipos corretos:

Arquivo	Colunas Ajustadas	Tipo de Ajuste
Campanhas	id_template, status_fim	Texto → Integer
Conversões	status_codigo	Texto → Integer
Clientes	status_codigo, atualizado_por	Texto → Integer / String
Endereços	status_codigo	Texto → Integer
Lojas	status_codigo	Texto → Integer
Pedidos	data_agendamento, status_codigo	Texto → Datetime / Integer
Templates	N/A	Todos os tipos corretos

Conclusão: Todos os arquivos estão prontos para análise e geração de gráficos, KPIs e dashboards.


14. Insights e Conclusões sobre KPIs

14.1 Comportamento de Clientes

- **Clientes Ativos vs Inativos:** Cerca de 29% dos clientes estão ativos nos últimos 30 dias, enquanto 71% estão em risco (Alerta, Atenção ou Sumido). Isso evidencia a necessidade de estratégias de retenção, como campanhas promocionais direcionadas ou programas de fidelidade.
- **Clientes Novos:** Representam aproximadamente 12% da base total, indicando que a aquisição de novos clientes é contínua, mas precisa ser complementada com ações de retenção.
- **Clientes Recuperados:** Embora representem apenas 8% do total, são uma oportunidade estratégica de engajamento, mostrando que campanhas de reativação funcionam e devem ser otimizadas.
- **Clientes em Fidelização:** Apenas 10% da base realiza mais de 3 compras nos últimos 90 dias, evidenciando que o nível de fidelidade é baixo e que estratégias de incentivo são necessárias.

14.2 Desempenho de Vendas

- Ticket Médio Geral: O valor médio dos pedidos é de aproximadamente R\$ 85, indicando predominância de pedidos de baixo a médio valor.
- Segmentação por Ticket:
 - Baixo (<50): 40% dos pedidos
 - Médio (50–100): 45% dos pedidos
 - Alto (>100): 15% dos pedidosIsso sugere que campanhas de upselling e cross-selling podem aumentar o ticket médio e a receita total.
- Evolução Mensal: Observa-se crescimento estável de 3% a 5% mês a mês, com picos em datas promocionais. Esses dados podem guiar decisões de estoque e logística.




14.3 Comportamento Temporal


- Vendas por Período do Dia:

Conforme a classificação de período do dia definida anteriormente, observa-se que o período da noite concentra o maior volume de pedidos, sendo o horário crítico para operação, atendimento e marketing digital.

VOLUME DE PEDIDOS POR PERÍODO DO DIA




VOLUME DE PEDIDOS POR DIA DA SEMANA



- Histograma e Boxplot de Valores: Mostram grande concentração de pedidos abaixo de R\$ 100, com alguns outliers significativos acima de R\$ 500, que devem ser analisados para verificar promoções ou clientes corporativos.

DISPERSÃO E OUTLIERS DO FATURAMENTO (Boxplot)



14.4 Performance de Campanhas e CRM

- Status de Campanha: A taxa de abertura (Read) é de 45%, mostrando bom engajamento. No entanto, 20% das campanhas enviadas nunca foram lidas (Send), indicando espaço para otimização de comunicação.

14.5 Insights Estratégicos

1. Oportunidades de Retenção: Focar em clientes em Alerta ou Atenção com campanhas personalizadas e promoções de incentivo.
2. Upselling e Cross-Selling: Direcionar ações para clientes de ticket médio baixo ou médio para aumentar receita.
3. Otimização do Horário de Campanhas: Reprogramar campanhas para o período noturno (18h–23h), priorizando canais com maior taxa de abertura, visando aumento da conversão e receita incremental.
4. Fidelização de Clientes Recorrentes: Criar programas de recompensas para clientes em Fidelização e Recuperados, incentivando mais compras em menor intervalo de tempo.
5. Monitoramento Contínuo de KPIs: Usar o dashboard para acompanhar em tempo real a evolução de clientes ativos, novos, recuperados e sumidos, permitindo ajustes rápidos em ações de marketing e operações.
6. Implementar campanhas automatizadas de reativação para clientes em alerta (30–60 dias), com cupons progressivos de desconto.

15. Próximos Passos

- Construção de dashboard interativo (Power BI ou Looker Studio)

- Implementação de modelo RFM (Recência, Frequência, Monetização)
- Criação de score de churn
- Automação do pipeline de dados
- Integração com dados em tempo real

16. Reprodutibilidade e Implementação Técnica

Todo o processo de limpeza, transformação, integração e cálculo de KPIs foi implementado em scripts desenvolvidos em Python, garantindo reprodutibilidade e escalabilidade do pipeline de dados.

O código-fonte completo está disponível no repositório GitHub, permitindo versionamento, manutenção e evolução contínua do projeto.

17. Conclusão

A base de dados foi devidamente tratada, padronizada e estruturada, garantindo qualidade e confiabilidade para análises futuras.

O pipeline de dados encontra-se preparado para suportar dashboards analíticos e atualizações contínuas, permitindo suporte efetivo à tomada de decisão.

A próxima etapa do projeto consiste na construção do dashboard interativo com base nos indicadores definidos.